



**Instituto Politécnico Nacional  
Unidad Profesional Interdisciplinaria de  
Ingeniería campus Zacatecas**

**Área de ubicación para el desarrollo del  
trabajo**

Ingeniería en Sistemas Computacionales

**Línea de investigación**

Inteligencia Artificial

**Título del proyecto de Trabajo Terminal**

Clasificación fenológica del frijol usando  
modelos de inteligencia artificial

**Presenta(n):**

Alonso Domínguez López  
Guillermo Ordaz Rodríguez  
Jesús Miguel Hernández García

**Director:**

Dr. Teodoro Ibarra Pérez

**Asesores:**

M. en C. Erika Paloma Sánchez  
Femat



Zacatecas, Zacatecas a 14 de mayo de 2024

# Índices

## 1. Índice de contenido

Resumen.....	4
1. Definición del problema.....	4
1.1 Contexto y antecedentes generales del problema.....	5
1.2 Situación problemática o problema de investigación .....	5
2. Estado del arte.....	6
3. Descripción del proyecto.....	12
3.1. Productos Esperados .....	12
3.2. Resultados esperados.....	12
4. Objetivo general del proyecto.....	13
4.1. Objetivos particulares del proyecto .....	13
5. Justificación.....	13
6. Hipótesis .....	14
7. Marco teórico.....	14
8. Factibilidad del proyecto .....	18
8.1. Recursos humanos.....	18
8.2. Equipo e instalaciones necesarias .....	18
8.3. Costo estimado y financiamiento .....	19
Bibliografía .....	20
Firmas.....	22
Autorización. ....	22
Currículum Vitae del director y los asesores del proyecto de TT. ....	23

## 2. Índice de tablas

Tabla 1. Comparación de la precisión del enfoque basado en CNN (CNN-BA) y el enfoque basado en Características Extraídas Manualmente (MEF-BA) [2] .....	7
Tabla 2. Recursos humanos .....	18
Tabla 3. Equipo, herramientas, instalaciones necesarias .....	18

## 3. Índice de figuras

Figura 1. Comparación entre los resultados de transferencia de U-Net y RF a diferentes escalas [4] .....	9
Figura 2. Clasificación de etapas fenológicas de cultivos de manzana mediante aprendizaje por transferencia [12] .....	10

# Resumen

En el presente trabajo se expone la propuesta de desarrollar un sistema embebido para la clasificación fenológica del frijol usando modelos de inteligencia artificial y aprendizaje profundo. Esto con el fin de contribuir a la industria agrícola en su labor, la cual tiene gran impacto en la alimentación y salud humana. La falta de un correcto y oportuno análisis fenológico puede ocasionar diversos problemas como la pérdida de datos sobre los ciclos de vida de las plantas, información crucial para comprender cómo están respondiendo los organismos a los cambios ambientales; dificultad para programar operaciones y maximizar los rendimientos en el campo, ocasionando que el agricultor falle al momento de determinar los momentos óptimos para plantar, cosechar y realizar otras actividades agrícolas; riesgos en la salud humana, ya que afecta la aparición de alergias estacionales y la transmisión de enfermedades transmitidas por vectores; entre otros. Por lo que, realizar una exploración fenológica precisa es crucial no solo para el ser humano, sino también para la conservación de ecosistemas. Es así que, como producto final, se espera obtener un producto completamente funcional que haga gala de un buen diseño de software y hardware, pues este consistirá en un dispositivo con cámara que identifique la etapa fenológica de los cultivos de frijol en tiempo real, que podrá ser usado para fines profesionales, que requieran gran precisión, y para propósitos didácticos como aporte a la formación de alumnos.

**Palabras clave:** Fenología, inteligencia artificial, redes neuronales convolucionales (CNN), sistema embebido, aprendizaje profundo.

## 1. Definición del problema

La agricultura siempre ha tenido una gran importancia en el correcto desarrollo del ser humano al ser, el campo, uno de los principales proveedores de alimentos. Por tanto, garantizar un desempeño profesional por parte de los responsables del mantenimiento del campo es vital. Sin embargo, el agricultor no siempre puede ser asertivo en la toma de decisiones, a menos que tenga amplia experiencia en el campo. Disminuir el error es necesario para tomar las mejores decisiones que influyen directamente en el rendimiento del cultivo, su calidad, la aparición de plagas y/o enfermedades.

Así, cobra gran importancia elaborar un software que pueda introducirse en un sistema embebido para realizar un análisis fenológico en tiempo real y que genere una respuesta que ayude a la toma de decisiones oportunas en el cuidado de los cultivos. Hasta este momento, el software desarrollado con el mismo propósito no se ha incluido en un sistema embebido que, con

un buen diseño de hardware, sea capaz de realizar un análisis en tiempo real; además, estos trabajos han tenido como limitantes los conjuntos de datos utilizados para realizar el entrenamiento de sus redes neuronales profundas (CNN por sus siglas en inglés), lo que provoca una disminución en la precisión general del modelo como el estudio realizado por Ibarra-Pérez, et al. [13].

## **1.1 Contexto y antecedentes generales del problema**

El frijol es la leguminosa de mayor consumo en México, su trascendencia es económica, social y estratégica para el sector agrícola rural del país. Durante el periodo de 2018 a 2020, en México se destinó una superficie promedio para la siembra del cultivo de 1.58 millones de ha y se produjeron 1.06 millones de t, con un valor comercial de 14 717.12 millones de pesos. El 88.4 % de las siembras de frijol se realizan en condiciones de temporal con rendimientos promedio de 570 kg ha<sup>-1</sup>. En México se cultivan 70 variedades de la leguminosa y la producción se diversifica en tres tipos, el 36 % es de claros, 31 % de negros y 29 % de pintos [5].

De acuerdo con Velia et al. [5] Las entidades con mayor producción se encuentran en la región centro-norte: Zacatecas, Durango, Chihuahua, San Luis Potosí y Guanajuato. Estos estados resultan beneficiados por su clima templado-semiárido, sin embargo, sus suelos poco profundos, con bajo contenido de materia orgánica y baja capacidad de retención de humedad, acentúan los efectos de sequía, por lo que la escasez de lluvia de los últimos años ha afectado su nivel de producción, ocasionando una alteración directa en la producción nacional. Por su parte, la región noreste tiene un clima cálido con invierno seco, donde se produce bajo condiciones de riego y humedad residual.

## **1.2 Situación problemática o problema de investigación**

La selección del sistema embebido o microcontrolador adecuado es fundamental para el desarrollo del proyecto, ya que determinará en gran medida la viabilidad y el rendimiento del sistema. Sin embargo, la falta de claridad sobre qué tipo de sistema utilizar y en qué lenguaje programarlo representa un desafío significativo. La programación de redes neuronales convolucionales (CNN) requiere un entorno de desarrollo específico, lo que añade complejidad al proceso.

Además, la disponibilidad y el costo de los microcontroladores compatibles con este tipo de aplicaciones pueden ser obstáculos adicionales. Encontrar un microcontrolador que cumpla

con los requisitos técnicos necesarios y que sea asequible puede resultar complicado. Es crucial identificar un microcontrolador capaz de soportar adecuadamente las demandas computacionales de las CNN, lo que limita aún más las opciones disponibles y podría implicar un costo adicional.

La falta de experiencia especializada en el agricultor sobre el manejo de cultivos para la toma de decisiones acertadas puede repercutir de manera significativa en el rendimiento y la calidad del cultivo, generando un área de oportunidad para el desarrollo de tecnología que permita apoyar al agricultor en la toma de decisiones agrícolas. En este sentido, se propone la implementación de un sistema embebido en tiempo real para dar solución a los problemas antes mencionados.

## **2. Estado del arte**

El desarrollo de la tecnología ha permitido realizar avances sustanciales y dar soluciones a diversas problemáticas a nivel mundial, entre ellas las relacionadas con la agricultura y la seguridad alimentaria, por lo que diversos investigadores han hecho uso de múltiples herramientas de inteligencia artificial para dar solución a dichos problemas.

El uso de redes neuronales convolucionales (CNN por sus siglas en inglés) ha despertado especial interés entre los investigadores, tal es el caso de Yalcin et al. [2] que propone un modelo de aprendizaje profundo para reconocer y clasificar las etapas fenológicas de plantas agrícolas, haciendo una recolección de datos mediante agroestaciones terrestres.

Se utilizó AlexNet como una red convolucional previamente entrenada con las imágenes del conjunto de datos del Sistema de Monitoreo e Información Agrícola Turco (TARBIL por sus siglas en inglés). AlexNet, es una red neuronal convolucional que consta de perceptrones multicapa (MLP, por sus siglas en inglés). Los MLP están compuestos por múltiples capas de convolución, agrupación, una unidad de rectificación lineal (ReLU, por sus siglas en inglés) bien conectadas. Las representaciones de las características aprendidas, llamadas mapas de características, se obtienen convolucionando un filtro (kernel) sobre la entrada y aplicando una función de activación (ReLU). Los mapas de características en una capa convolucional convolucionan los pesos que se pueden aprender con mapas de características en capas anteriores, lo que se conoce como proceso de propagación hacia adelante (forward propagation).

Se utilizaron 280 imágenes para el entrenamiento y 120 para realizar las pruebas, creando así 30 imágenes de muestra para cada etapa de crecimiento. Se compararon los resultados obtenidos mediante el uso de CNN con los obtenidos mediante técnicas clásicas de aprendizaje

automático basadas en características extraídas manualmente. Estas características se combinaron para alimentar un algoritmo de aprendizaje automático compuesto por un clasificador Naive-Bayes. Como resultado, se mostró que la solución que emplea características extraídas manualmente es superada por las características aprendidas del modelo de CNN. Además, el rendimiento de la configuración del CNN fue inferior al clasificar las etapas fenológicas tempranas de las plantas, a diferencia de la clasificación de las últimas etapas cuyo rendimiento fue superior.

En la Tabla 1 se muestra la comparación de resultados entre dos arquitecturas diferentes, una CNN y otra llamada Extracción Manual de Características (MEF-FA).

*Tabla 1. Comparación de la precisión del enfoque basado en CNN (CNN-BA) y el enfoque basado en Características Extraídas Manualmente (MEF-BA) [2]*

<b>Dataset</b>	<b>Método</b>	<b>Precisión</b>	<b>Recall</b>	<b>F1-Score</b>	<b>Accuracy</b>
		%	%	%	%
<b>Trigo</b>	<b>MEF-BA</b>	75.51	74.53	74.57	74.53
<b>Cebada</b>	<b>MEF-BA</b>	72.21	71.68	72.21	71.43
<b>Lenteja</b>	<b>MEF-BA</b>	69.42	68.83	69.31	68.97
<b>Algodón</b>	<b>MEF-BA</b>	81.74	80.72	80.66	80.89
<b>Pimiento</b>	<b>MEF-BA</b>	83.44	82.52	82.26	82.41
<b>Maíz</b>	<b>MEF-BA</b>	82.71	81.73	81.62	81.86
<b>Trigo</b>	<b>CNN-BA</b>	82.62	83.64	83.68	83.64
<b>Cebada</b>	<b>CNN-BA</b>	79.32	77.34	78.43	77.15
<b>Lenteja</b>	<b>CNN-BA</b>	74.21	73.62	74.17	73.76
<b>Algodón</b>	<b>CNN-BA</b>	87.32	86.14	86.58	86.54
<b>Pimiento</b>	<b>CNN-BA</b>	88.12	87.24	87.28	87.14
<b>Maíz</b>	<b>CNN-BA</b>	87.32	86.14	86.58	86.54

Por otro lado, Yang et al. [3] emplea un enfoque que identifica las principales etapas de crecimiento del arroz directamente a partir de imágenes RGB, estas imágenes son monotemporales y se obtuvieron haciendo una detección fenológica en un área grande utilizando un vehículo aéreo no tripulado (UAV por sus siglas en inglés), introduciendo los datos obtenidos en una red bien entrenada. Se aborda la detección precisa de la fenología de los cultivos mediante el uso de datos de teledetección de alta resolución temporal. Se señala que la recopilación y

análisis de estos datos pueden llevar mucho tiempo, especialmente en condiciones climáticas adversas para los vuelos de vehículos aéreos no tripulados. Se evaluó un método llamado SMF (Smooth Manifold Fitting) utilizando diferentes longitudes e intervalos de datos de series temporales.

Los resultados mostraron que el mejor rendimiento del método SMF se logró utilizando todos los datos disponibles de series temporales. Se obtuvo un RMSE (Root Mean Square Error) de 4,04 días para las fechas fenológicas estimadas, y una tasa de precisión del 68,8%, con un MAE (Error Absoluto Medio) de 0,318 para la etapa fenológica principal estimada. Sin embargo, se observó que el rendimiento del método disminuyó cuando se utilizaron menos datos con intervalos de observación más grandes.

Se utilizaron 4 tipos diferentes de redes en las que se examinaron dos estrategias de entrenamiento, incluido el entrenamiento directo de las redes en el conjunto de datos obtenido y el entrenamiento previo de las redes en el conjunto de datos ImageNet. Además, existe una mejor concordancia entre la etapa fenológica principal estimada y observada cuando las redes se entrenaron en el conjunto de datos ImageNet. Esto se debe a que se puede obtener un mejor extractor de características entrenando la red con un conjunto de datos grande que en un conjunto de datos pequeño.

Aunado a esta línea de investigación, Ge et al. [4] se distanció de los modelos convencionales como el de “una sola vez, un solo lugar” para entrenar un modelo U-Net respaldado con los datos de Cropland Data Layer (CDL) y Landsat. Se generaron dos imágenes temporales correspondiente a los periodos de siembra y crecimiento vigoroso y, para garantizar la coherencia de distribución de datos entre las áreas objetivo y el área de entrenamiento, se cambiaron las ventanas temporales de las áreas objetivo haciéndolas coincidir con las del área de entrenamiento siguiendo el principio de coincidencia fenológica.

El estudio compara dos algoritmos de aprendizaje automático, U-Net y Random Forest (RF), en la tarea de clasificación de imágenes para identificar áreas de cultivo específicas. En la Figura 1, se observa que U-Net tiene una precisión general y una puntuación F1 más altas que RF en la mayoría de las áreas objetivo, excepto en T8 y T9.

Se señala que el rendimiento de U-Net disminuye significativamente cuando la forma, el tamaño o la estructura de los datos objetivo difieren de los datos de entrenamiento. Aunque el estudio utiliza el método de mover la ventana de tiempo para mantener la misma distribución de los valores espectrales, aún existen diferencias en la forma y el tamaño de los objetos en



diferentes áreas objetivo, lo que limita el rendimiento de generalización de U-Net.

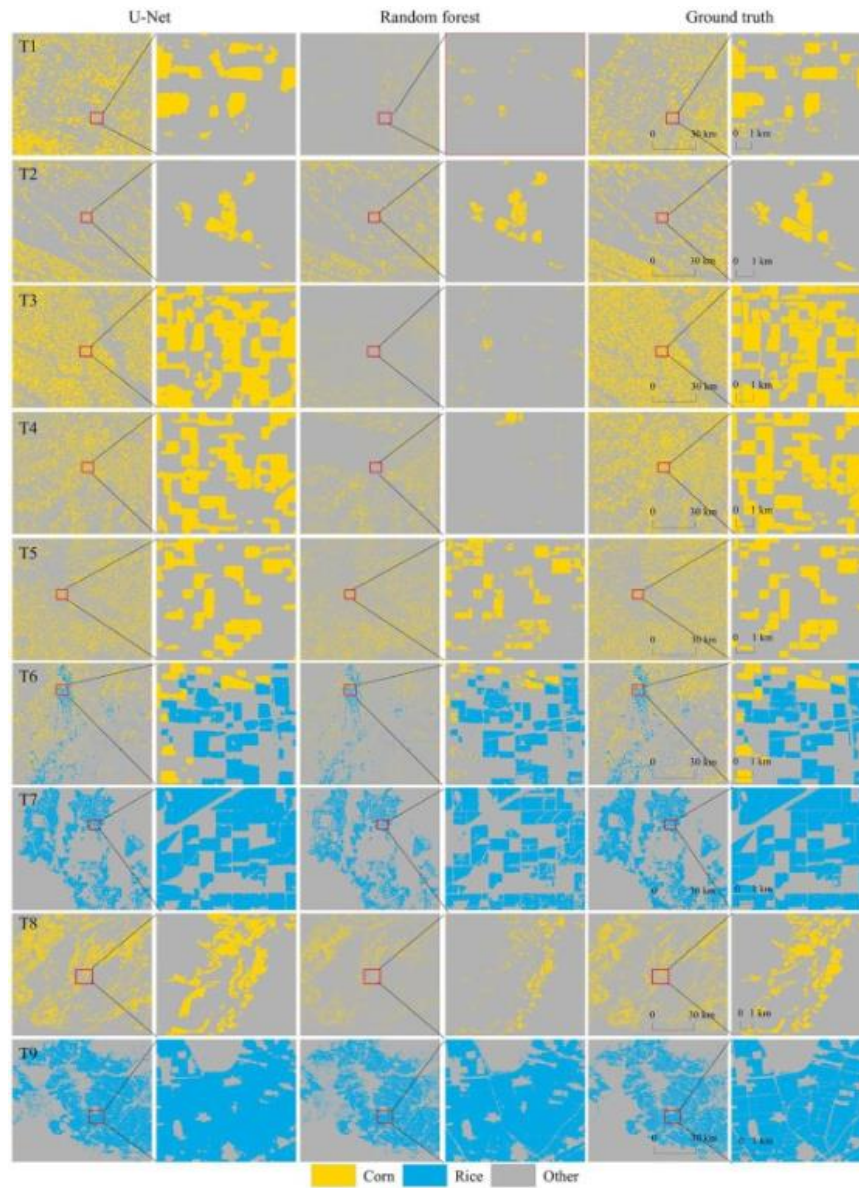


Figura 1. Comparación entre los resultados de transferencia de U-Net y RF a diferentes escalas [4]

Para la caracterización e identificación de las etapas fenológicas del frijol existen antecedentes de detección de otros cultivos. Datt et al [12] propone un modelo de CNN para el reconocimiento de ocho etapas fenológicas diferentes de cultivos de manzana, es decir, etapa de madurez y senescencia de frutas, brotación/ desarrollo de Bud, floración, etc, desarrollo de hoja, comienzo de la latencia, desarrollo de frutas, desarrollo de brotes, emergencia de inflorescencia. El modelo de aprendizaje de transferencia que se eligieron fue el modelo Inception-v3 (modelo pre-entrenado). Para entrenar el modelo, crearon un conjunto de datos de imágenes de alta calidad de diferentes etapas fenológicas recogidas de un huerto en Srinagar, India, utilizando una cámara

DSLR. Originalmente se capturaron más de 1200 imágenes RGB pertenecientes a 8 clases diferentes. El conjunto de datos se amplió a 7000 fotos utilizando técnicas de aumento de datos. El rendimiento del modelo que propusieron se comparó con otros algoritmos como VGG16, ResNet50, Xception y VGG19. El F1-Score del modelo fue de 98%, mientras que la de los demás modelos Xception, Inception-v3, ResNet50, VGG16 y VGG19 fue de 97%, 96%, 66% y 95%, respectivamente.

Este artículo particularmente en su conjunto de datos fue limitado. Al contar sólo con 1200 imágenes optaron por la técnica de aumento de datos, lo que es dentro de todos los males el mal menor, pero que sigue siendo una limitante al momento de entrenar su modelo. Nuestra propuesta tendrá una base de datos enorme para el entrenamiento y validación de aprendizaje de la red.

En la Figura 2 se muestra un esquema de cómo se llevó a cabo la clasificación de las etapas fenológicas de cultivos de manzana.

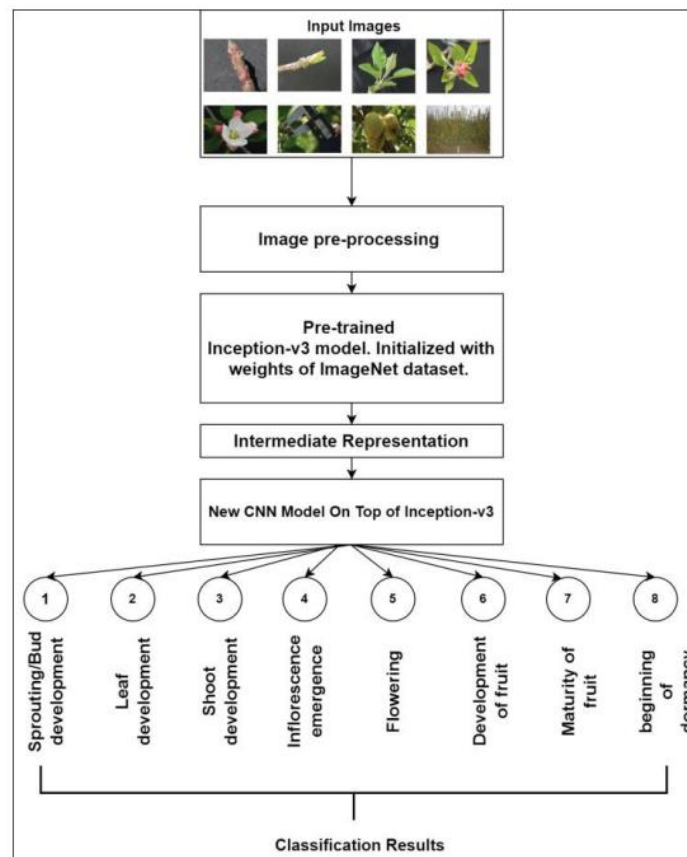


Figura 2. Clasificación de etapas fenológicas de cultivos de manzana mediante aprendizaje por transferencia [12]

Finalmente, Ibarra-Pérez et al. [13] aplicó un enfoque de aprendizaje por transferencia y

un método de aumento de datos. Se utilizó una estación equipada con cámaras RGB para recolectar datos de imágenes durante el ciclo fenológico completo del frijol. La información recopilada se utilizó para crear un conjunto de datos para evaluar el rendimiento de cada uno de los cuatro modelos de red propuestos: AlexNet, VGG19, SqueezeNet y GoogleNet.

AlexNet es una arquitectura que se caracteriza por utilizar una nueva función de activación (ReLU), para agregar no linealidad, resolver el problema del gradiente evanescente y acelerar el entrenamiento de la red.

VGG19 es un modelo de red neuronal convolucional (CNN) que fue desarrollado por el Visual Geometry Group (VGG) en la Universidad de Oxford. La arquitectura VGG19 se compone de 19 capas (de ahí su nombre) y sigue un patrón simple de convoluciones y capas de pooling, seguido por varias capas completamente conectadas al final.

SqueezeNet es su arquitectura comprimida, que se logra mediante el uso de una combinación de fire module, que son filtros de convolución 1x1, y capas de pooling. Estas capas 1x1 se utilizan para reducir la dimensión de los mapas de características antes de las capas de pooling, lo que reduce significativamente el número de parámetros en comparación con arquitecturas más tradicionales.

GoogleNet, también conocida como Inception v1, es una arquitectura de red neuronal convolucional (CNN) desarrollada por investigadores de Google en 2014. En lugar de usar solo convoluciones de tamaño fijo, GoogleNet utiliza módulos de Inception que contienen convoluciones de 1x1, 3x3 y 5x5, así como capas de pooling, para capturar características en diferentes escalas espaciales. A través de la utilización de convoluciones 1x1 y módulos de Inception, GoogleNet logra una reducción significativa en el número de parámetros en comparación con arquitecturas anteriores, como AlexNet o VGG.

Las métricas utilizadas fueron exactitud, precisión, sensibilidad, especificidad y puntuación F1. La metodología utilizada en este estudio consta de tres fases. La primera fase describe el procedimiento de adquisición de datos y la construcción y características generales de las imágenes obtenidas. La segunda fase describe el aprendizaje por transferencia de las arquitecturas CNN utilizadas en este estudio y la configuración de hiperparámetros, como la tasa de aprendizaje, el tamaño del lote por iteración, el número de épocas y el optimizador. La tercera fase describe la evaluación de los modelos propuestos para medir el desempeño aplicando diferentes métricas. Mediante un análisis metodológico, se comparó y evaluó el desempeño aplicando cinco métricas a cuatro modelos CNN. La arquitectura GoogleNet obtuvo el mejor

rendimiento, mostrando los mejores resultados en la mayoría de las métricas, obteniendo 96,71% de precisión, 96,81% de precisión, 95,77% de sensibilidad, 98,73% de especificidad y 96,25% de F1-Score.

### **3. Descripción del proyecto**

El presente proyecto de Trabajo Terminal tiene como objetivo desarrollar un sistema embebido capaz de identificar las etapas fenológicas de la planta de frijol mediante imágenes tomadas en tiempo real haciendo uso de redes neuronales convolucionales (CNN). La identificación precisa de las etapas fenológicas es crucial para optimizar prácticas agrícolas y mejorar los rendimientos de los cultivos.

#### **3.1. Productos Esperados**

- Base de Datos de Imágenes: Una base de datos compuesta por aproximadamente 10,000 imágenes de 250x250 píxeles, capturadas en diferentes condiciones y representando las diversas etapas fenológicas de la planta de frijol.
- Modelo Entrenado: Un modelo CNN diseñado y entrenado para clasificar las imágenes de la planta de frijol en sus respectivas etapas fenológicas con alta precisión. El modelo será entrenado utilizando bibliotecas como TensorFlow y Keras, y optimizado para su implementación en un entorno embebido utilizando TinyML.
- Hardware: Un microcontrolador Raspberry Pi, una cámara para capturar imágenes en tiempo real y una pantalla LCD para mostrar los resultados. La Raspberry Pi estará equipada con un sistema operativo Linux ligero.
- Software: Integración en Python que integrará la captura de imágenes, el procesamiento con la CNN entrenada y la visualización de los resultados. Este software permitirá la identificación y visualización en tiempo real de la etapa fenológica de la planta de frijol.

#### **3.2. Resultados esperados**

- Identificación Precisa de las Etapas Fenológicas: El sistema será capaz de identificar las etapas fenológicas de la planta de frijol con una alta precisión, gracias al modelo CNN entrenado y optimizado. Se espera que el modelo alcance una precisión superior al 90% en la clasificación de las imágenes.
- Rendimiento en Tiempo Real: El sistema embebido debe procesar y mostrar los

resultados en tiempo real, con un retardo mínimo desde la captura de la imagen hasta la visualización de la etapa fenológica en la pantalla LCD. Esto es crucial para aplicaciones en campo, donde la rapidez y la precisión son esenciales.

- **Facilidad de Uso y Portabilidad:** El sistema será diseñado para ser fácil de usar y portátil, permitiendo a los agricultores y técnicos agrícolas utilizarlo directamente en el campo. La interfaz de usuario será intuitiva, facilitando la captura de imágenes y la visualización de los resultados sin necesidad de conocimientos técnicos avanzados.
- **Impacto en la Agricultura:** La implementación exitosa de este sistema contribuirá a mejorar las prácticas agrícolas mediante la monitorización precisa de las etapas fenológicas de la planta de frijol. Esto permitirá tomar decisiones informadas sobre el manejo de cultivos, optimizando los recursos y aumentando la productividad.

## **4. Objetivo general del proyecto.**

Implementar un modelo de red neuronal profunda en un sistema embebido para identificar la etapa fenológica del frijol en tiempo real.

### **4.1. Objetivos particulares del proyecto**

- Recolectar imágenes para la generación del conjunto de datos de entrenamiento y pruebas de los modelos.
- Entrenar los modelos de redes neuronales profundas.
- Evaluar el rendimiento de los modelos para determinar la mejor arquitectura.
- Implementar el mejor modelo en un sistema embebido (microcontrolador).
- Diseñar y construir el dispositivo para montar el sistema embebido.

## **5. Justificación**

De acuerdo con la Organización de Comida y Agricultura de las Naciones Unidas (FAO) [1] las plagas representan cerca del 40% de las pérdidas de los cultivos a nivel mundial. Las plagas y enfermedades de las plantas suelen ser imposibles de erradicar una vez que se han establecido. En este sentido, la identificación oportuna de las etapas por las cuales una planta pasa en su vida permite identificar momentos críticos para que el agricultor pueda tomar una decisión oportuna. Estas decisiones influyen de manera significativa en el rendimiento del cultivo y su calidad. Un dispositivo que ayude con la identificación de estas etapas críticas sería de gran

ayuda para el agricultor el cuál solo tendría que llevarlo a campo y usar la información que le brinde para tomar una decisión de acción bien informada.

El proyecto se basa en la optimización del proceso de identificación de las etapas fenológicas en plantas de frijol mediante el uso de redes neuronales convolucionales (CNN) en tiempo real. A diferencia de otros enfoques que requieren el envío de información a la nube para su procesamiento, el sistema embebido puede realizar esta tarea de forma local y rápida [2].

Al procesar la información localmente, se reduce la dependencia de una conexión a internet estable, lo que puede ser especialmente importante en áreas remotas o con acceso limitado a la red. Además, al eliminar la necesidad de enviar datos a la nube, se mejora la privacidad y seguridad de la información, ya que los datos permanecen en el dispositivo local. Al procesar las imágenes en tiempo real, se puede obtener información instantánea sobre el estado fenológico de las plantas, lo que permite una toma de decisiones más rápida y eficiente en actividades agrícolas como la planificación de la cosecha, el riego y la aplicación de fertilizantes o pesticidas.

## **6. Hipótesis**

Se plantea que un sistema embebido con una red neuronal convolucional entrenada para identificar las etapas fenológicas de una planta de frijol a partir de imágenes tomadas por una cámara en tiempo real facilitará a los agricultores la identificación precisa de la etapa de crecimiento de sus plantas. Se espera que este sistema simplifique la tarea de determinar los cuidados necesarios en cada etapa, como el riego, el control de plagas, enfermedades y la fertilización, mejorando así la eficiencia y la calidad del cultivo. Además, se espera que esta mejora en la gestión agrícola contribuya a reducir la pérdida de cosecha.

## **7. Marco teórico**

El presente estudio se enmarca en la aplicación de tecnologías avanzadas en el ámbito agrícola, específicamente en la identificación automatizada de etapas fenológicas en plantas de frijol. Para comprender la relevancia y el contexto de esta investigación, es fundamental revisar los conceptos clave.

### **7.1. Frijol**

El frijol común (*Phaseolus vulgaris* L.) es una de las leguminosas más importantes para el consumo humano directo, es considerado como una fuente económica y esencial de proteínas, minerales como hierro y zinc, y carbohidratos como fibra dietética y oligosacáridos. Adicionalmente, el frijol es importante por su contenido de fitoquímicos sintetizados del metabolismo secundario, como los polifenoles, fitoesteroles y saponinas [5].

La fenología de las plantas de frijol se refiere al estudio de las diferentes etapas de crecimiento y desarrollo que experimentan estas plantas a lo largo de su ciclo de vida. Estas etapas incluyen desde la germinación, hasta la cosecha. Identificar correctamente estas etapas es crucial para determinar el momento óptimo de aplicación de prácticas agrícolas. A continuación, se describe cada una de las etapas:

V0 germinación: se toma como iniciación de esta etapa el día que la semilla tiene humedad suficiente para el comienzo de este proceso; es decir, el día del primer riego, o de la primera lluvia si se siembre en un suelo seco. v1 emergencia: se inicia cuando los cotiledones de la planta aparecen a nivel del suelo. v2 hojas primarias: comienza cuando las hojas primarias (unifoliadas y compuestas) están desplegadas. v3 primeras hojas trifoliadas: se inicia cuando la planta presenta la primera hoja trifoliada completamente abierta y las láminas de los folíolos se ubican en un plano. v4 tercera hoja trifoliada: cuando la tercera hoja trifoliada se encuentra desplegada. r5 prefloración: inicia cuando aparece el primer botón o racimo. r6 floración: cuando la planta presenta la primera flor abierta. r7 formación de las vainas: cuando la planta presenta la primera vaina con corola de la flor colgada o desprendida. r8 llenado de la vaina: se inicia cuando la primera vaina empieza a llenar. es el inicio del crecimiento activo de la semilla. las vainas presentan abultados que corresponden a las semillas en crecimiento. r9 maduración: se caracteriza por el inicio de coloración y secado en las primeras vainas, continúa el amarillamiento, la caída de hojas y todas las partes de la planta se secan; las vainas al secarse pierden su pigmentación. el contenido de agua en las semillas baja hasta alcanzar 15%, momento en el cual las semillas adquieren su color típico. termina el ciclo biológico y el cultivo se encuentra listo para su cosecha [6].

## **7.2. Agricultura de precisión**

El concepto sobre el que se basa la agricultura de precisión es aplicar la cantidad correcta de insumos, en el momento adecuado y en el lugar exacto. Es el uso de la tecnología de la información para adecuar el manejo de suelos y cultivos a la variabilidad presente dentro de un lote. La agricultura de precisión (AP) involucra el uso de sistemas de posicionamiento global

(GPS) y de otros medios electrónicos para obtener datos del cultivo. Las tecnologías de la agricultura de precisión permiten satisfacer una de las exigencias de la agricultura moderna: el manejo óptimo de grandes extensiones. Se presenta como principal ventaja que el análisis de resultados de los ensayos se puede realizar por sectores diferentes dentro de un mismo lote, y de esta manera ajustar el manejo diferencial dentro de los mismos [11].

### **7.3. Deep Learning**

Deep Learning es una rama de Machine Learning que utiliza redes neuronales para enseñar a equipos informáticos a hacer lo que resulta natural para las personas: aprender a partir de ejemplos. Con Deep Learning, un modelo aprende a realizar tareas de clasificación o regresión directamente a partir de datos de imágenes, texto o sonido [10].

Los modelos de Deep Learning se basan en arquitecturas de redes neuronales. Inspirada en el cerebro humano, una red neuronal consta de neuronas o nodos interconectados en una estructura en capas que relacionan las entradas con las salidas deseadas. Las neuronas situadas entre las capas de entrada y salida de una red neuronal se denominan capas ocultas. El término “Deep” (profundo) normalmente alude a la cantidad de capas ocultas de la red neuronal. Los modelos de Deep Learning pueden tener cientos o incluso miles de capas ocultas [10].

### **7.4. Redes Neuronales Convolucionales (CNN)**

En la identificación de las etapas fenológicas de la planta de frijol se hará uso de inteligencia artificial, La Inteligencia Artificial (IA) es un campo de la informática que se enfoca en el desarrollo de sistemas y tecnologías capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la percepción y la toma de decisiones.

La inteligencia artificial (IA) es una simulación del comportamiento inteligente humano. Es el software de un equipo o sistema diseñado para que perciba su entorno, tome decisiones y realice acciones. La forma en que estas aplicaciones implementan la inteligencia artificial puede variar, pero la tecnología subyacente, los modelos de Machine Learning y Deep Learning utilizados para crear un sistema que puede tomar decisiones, permanece constante [7].

Dentro de la IA, las Redes Neuronales Convolucionales (CNN) son un tipo de modelo inspirado en la estructura y función del cerebro humano, especialmente efectivo en el procesamiento de datos de imágenes y reconocimiento de patrones.

Una red neuronal convolucional (CNN o ConvNet) es una arquitectura de red para Deep



Learning que aprende directamente a partir de datos. Son particularmente útiles para identificar patrones en imágenes con el fin de reconocer objetos, clases y categorías. Además, pueden ser muy eficaces para clasificar datos de audio, señales y series temporales [7].

Las redes neuronales convolucionales pueden tener decenas o cientos de capas, y cada una de ellas aprende a detectar diferentes características de una imagen. Se aplican filtros a las imágenes de entrenamiento con distintas resoluciones, y la salida resultante de convolucionar cada imagen se emplea como entrada para la siguiente capa. Los filtros pueden comenzar como características muy simples, tales como brillo y bordes, e ir creciendo en complejidad hasta convertirse en características que definen el objeto de forma singular [8].

### **7.5. Sistemas embebidos**

La red neuronal que se espera trabajar tiene como fin establecerse en un sistema embebido para poder trabajar en tiempo real con este, un sistema embebido se puede definir de la siguiente forma. Se conoce como sistema embebido a un circuito electrónico computarizado que está diseñado para cumplir una labor específica en un producto. La inteligencia artificial, secuencias y algoritmos de un sistema embebido, están residentes en la memoria de una pequeña computadora denominada microcontrolador. A diferencia de los sistemas computacionales de oficina y laptops, estos sistemas solucionan un problema específico y están dispersos en todos los ambientes posibles de la vida cotidiana [9].

Un sistema operativo es un programa que se ejecuta continuamente en un dispositivo, brindando una capa de abstracción para los usuarios facilitándole el uso del dispositivo; además de ocultar el hardware del sistema y encargarse de la administración de sus recursos. Un sistema operativo embebido es un sistema operativo que se ejecuta sobre un sistema embebido, los cuales han sido descritos previamente. Los sistemas operativos embebidos generalmente se ejecutan sobre dispositivos que difieren de un computador común, como televisores, hornos microondas, y teléfonos móviles. Usualmente tienen algunas características de sistemas de tiempo real, pero a la vez tienen restricciones de tamaño, memoria y energía que los hacen especiales.

Linux embebido es un sistema Linux típico del cual se han removido programas de utilidad, herramientas, y otros servicios del sistema que no son necesarios en un ambiente embebido. Linux embebido posee una estructura en capas complementada con módulos. Estas capas generalmente son el kernel de Linux, el sistema de archivos, los drivers de dispositivos y los protocolos de red. Linux embebido toma el kernel de Linux y extrae los módulos que no son

necesarios. Dentro de la capa del kernel, Linux embebido está compuesto de cinco grandes subsistemas: el planificador de procesos, el manejador de memoria, el sistema de archivos virtual, la interfaz de red, y la comunicación entre procesos [14].

## 8. Factibilidad del proyecto

### 8.1. Recursos humanos

La Tabla 2 muestra los recursos humanos del proyecto. El asesor ayudará a los desarrolladores sobre sus dudas técnicas a la hora de desarrollar el proyecto. El director es el encargado de dirigir, controlar y apoyar sobre las decisiones de los desarrolladores.

*Tabla 2. Recursos humanos*

Nombre	Teléfono	Correo	Función
Jesús Miguel Hernández García	492-123-6465	<a href="mailto:jhernandezg1710@alumno.ipn.mx">jhernandezg1710@alumno.ipn.mx</a>	Desarrollador
Guillermo Ordaz Rodríguez	493-135-0760	<a href="mailto:gordazr2100@alumno.ipn.mx">gordazr2100@alumno.ipn.mx</a>	Desarrollador
Alonso Domínguez López	498-122-2264	<a href="mailto:adominguezl2100@alumno.ipn.mx">adominguezl2100@alumno.ipn.mx</a>	Desarrollador
Erika Paloma Sánchez Femat	492-238-9462	<a href="mailto:epsanchezf@ipn.mx">epsanchezf@ipn.mx</a>	Asesor
Teodoro Ibarra Pérez	492-265-8237	<a href="mailto:tibarra@ipn.mx">tibarra@ipn.mx</a>	Director

### 8.2. Equipo e instalaciones necesarias

La Tabla 3 rescata los recursos materiales, herramientas, software disponible que se cuenta para llevar a cabo la ejecución del proyecto.

*Tabla 3. Equipo, herramientas, instalaciones necesarias*

Equipos	Herramientas	Software	Instalaciones
Laptop Huawei D15 Matebook	SoC (microcontrolador)	Matlab	Laboratorios de cómputo de la UPIIZ
Laptop Dell Inspiron 15 3000	Cámara	Python	
Laptop ROG STRIX G533	Conexión a internet		

### **8.3. Costo estimado y financiamiento**

Para realizar una estimación del costo del proyecto, primero se deberán tomar en cuenta los costos de los equipos de trabajo que se utilizarán, siendo los siguientes:

- Laptop Huawei D15 Matebook: \$15,000.
- Laptop Dell: \$15,000.
- Laptop ROG STRIX G533Z: \$40,000.
- Raspberry Pi: \$1,200.
- Pantalla LCD: \$800.

Después, tenemos que, en promedio, estos equipos consumen alrededor de 16 kilovatios hora (kWh) al mes con un uso de 8 horas diarias, lo que representa un consumo total de 192 kWh durante el desarrollo del proyecto. Generándose así un costo aproximado de \$550.00 por consumo de energía eléctrica.

Otro factor importante para considerar es el uso de internet, este tiene una tarifa mensual de \$389.00, resultando en un costo de \$4,668.00 por doce meses. También se incluyen los gastos de transporte para los involucrados en el desarrollo, siendo este de \$72.00 diarios, generando un costo de \$1,240.00 al mes, por cinco días de trabajo a la semana, y un costo anual de \$14,880.00.

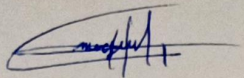
El costo total del proyecto será, aproximadamente, de \$92,098.00. Este parece un costo elevado; sin embargo, ya contamos con los equipos de cómputo y los gastos de luz e internet son cubiertos por la escuela. Los demás gastos serán cubiertos por el profesor a cargo de la dirección del proyecto.

## Bibliografía

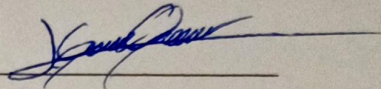
- [1] FAO. Food and Agriculture Organization of the United Nations International Year of Plant Health. Available online: <https://www.fao.org/plant-health-2020/about/en/> (accessed on 11 December 2023).
- [2] Yalcin, H. Phenology Recognition Using Deep Learning. In Proceedings of the 2018 Electric Electronics, Computer Science, Biomedical Engineerings' Meeting (EBBT); 2018; pp. 1–5.
- [3] Yang, Q.; Shi, L.; Han, J.; Yu, J.; Huang, K. A near Real-Time Deep Learning Approach for Detecting Rice Phenology Based on UAV Images. *Agric For Meteorol* 2020, 287, doi:10.1016/j.agrformet.2020.107938.
- [4] Ge, S.; Zhang, J.; Pan, Y.; Yang, Z.; Zhu, S. Transferable Deep Learning Model Based on the Phenological Matching Principle for Mapping Crop Extent. *International Journal of Applied Earth Observation and Geoinformation* 2021, 102, 102451, doi:10.1016/J.JAG.2021.102451.
- [5] Velia, A.; Garay, A.; Alberto, J.; Gallegos, A.; Muro, L.R. El Cultivo Del Frijol Presente y Futuro Para México; INIFAP: Celaya, Gto., México, 2021; Volume 1, ISBN 978-607-37-1318-4. [Google Scholar].
- [6] Dirección de Soluciones Geoespaciales, «Reporte\_de\_Aptitud\_agroclim\_tica\_de\_M\_xico\_del\_frijol\_PV\_2019,» Marzo 2019. [En línea]. Available: [https://www.gob.mx/cms/uploads/attachment/file/448930/Reporte\\_de\\_Aptitud\\_agroclim\\_tica\\_de\\_M\\_xico\\_del\\_frijol\\_PV\\_2019.pdf](https://www.gob.mx/cms/uploads/attachment/file/448930/Reporte_de_Aptitud_agroclim_tica_de_M_xico_del_frijol_PV_2019.pdf). [Último acceso: 16 Marzo 2024].
- [7] The MathWorks, Inc., «Introducción a la inteligencia artificial,» 2021. [En línea]. Available: <https://la.mathworks.com/discovery/artificial-intelligence.html>. [Último acceso: 16 Marzo 2024].
- [8] The MathWorks, Inc., «Introducción a la inteligencia artificial,» 2021. [En línea]. Available: <https://la.mathworks.com/discovery/artificial-intelligence.html>. [Último acceso: 16 Marzo 2024].
- [9] Galeano, G. (2009). Programación de sistemas embebidos en C. Alpha Editorial.

- [10] MathWorks, «Introduccion a deep learning,» [En línea]. Available: <https://la.mathworks.com/discovery/deep-learning.html>. [Último acceso: 19 Marzo 2024].
- [11] E. Garcia y F. Flego, «Agricultura de precision,» *Tecnología Agropecuaria*, pp. 99-116.
- [12] Datt, R.M.; Kukreja, V. Phenological Stage Recognition Model for Apple Crops Using Transfer Learning. In Proceedings of the 2022 2nd International Conference on Advance Computing and Innovative Technologies in Engineering (ICACITE); 2022; pp. 1537–1542.
- [13] Ibarra, T., Jaramillo, R., Correa, H. C., Ndjatchi, C., Martínez, M. R., Guerrero, H. A., Mirelez, F. D., Casas, J. I., Reveles, R., y Hernández, U. A., "Una comparación de rendimiento de modelos CNN para la clasificación de la fenología del frijol utilizando técnicas de aprendizaje por transferencia," *AgriEngineering*, vol. 6, no. 1, pp. 841-857, 18-03-2024.
- [14] Pérez, D. "Sistemas embebidos y sistemas operativos embebidos." *Lecturas en ciencias de la computación. Universidad Central de Venezuela, Vols. i de 2*ISSN (2009): 1316-6239.

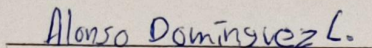
## **Firmas.**



Jesús Miguel  
Hernández García



Guillermo Ordaz  
Rodríguez

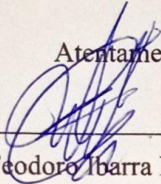


Alonso Domínguez  
López

## **Autorización.**

Por medio del presente autorizo la impresión y distribución del presente protocolo, toda vez que lo he leído, comprendido en su totalidad, y estar de acuerdo con su desarrollo.

Atentamente;



Dr. Teodoro Ibarra Pérez



M. en C. Erika Paloma Sánchez  
Femar

## **Curriculum Vitae del director y los asesores del proyecto de TT.**

En esta sección se deberán incluir el currículum vitae del director y los asesores del proyecto de Trabajo Terminal.

# ERIKA SÁNCHEZ-FEMAT

---

## EMPLEO

- Sr. Machine Learning Engineer - Konfío. Desde 2024
  - Docente - Instituto Politécnico Nacional. Desde 2023
  - Sr. Data Scientist - SoFi. 2022 - 2023
  - Sr. Data Scientist - Atrato. 2022 - 2022
  - Sr. Data Scientist - TrackChain. 2020 - 2022
  - Sr. Research Engineer (AI) - Barcelona Supercomputing Center. 2019 - 2021
- 

## VISITAS DE INVESTIGACIÓN

- Instituto Politécnico Nacional - Ciencias de la Computación. 2022 - 2023
  - Instituto Nacional de Astrofísica, Óptica y Electrónica - Ciencias de la Computación. November 2021
  - Universidad Nacional Autónoma de México - Departamento de Aplicaciones Matemáticas. October 2021
  - Universitat Politècnica de Catalunya - Inteligencia Artificial . 2019 - 2021
- 

## EDUCACIÓN

- INFOTEC - Maestría en Ciencia de Datos e Inteligencia Artificial. 2022
  - Instituto Politécnico Nacional - Ingeniería en Sistemas Computacionales. 2017
- 

## PREMIOS

- Titulación con Mención Honorífica por el Instituto Politécnico Nacional. 2017
- 

## ARTÍCULOS CIENTÍFICOS

- Simulation and Counting of Colony-Forming Units. ReCIBE. 2017
- Mobile Application for Automatic Counting of Bacterial Colonies. Springer. 2016



---

## CURSOS IMPARTIDOS

- Introducción a Python. Instituto Politécnico Nacional. 2024
- Introducción a Visión e Inteligencia Artificial. 2023

---

## CURSOS DE UNIVERSIDAD IMPARTIDOS

- Statistical Tools for Data Analytics. Instituto Politécnico Nacional. 2024
- Machine Learning. Instituto Politécnico Nacional. 2024
- Inteligencia Artificial. Instituto Politécnico Nacional. 2024
- Sistemas Operativos. Instituto Politécnico Nacional. 2024
- Análisis y Diseño de Algoritmos. Instituto Politécnico Nacional. 2023
- Análisis y Diseño de Sistemas. Instituto Politécnico Nacional. 2023

---

## IDIOMAS

- Español - Nativo
- Inglés - B2
- Francés - B2
- Catalán - A2

<b>Información personal</b>	<b>Dr. Teodoro Ibarra Pérez</b> <b>Candidato a Investigador Nacional SNI</b> tibarrap@ipn.mx
<b>Experiencia laboral</b> Fecha y cargo desempeñado Empresa o Institución Funciones y responsabilidades principales	<p><b>01/02/2013 – Actualidad. Profesor e investigador de Tiempo Completo Asociado B en la Unidad Profesional Interdisciplinaria de Ingeniería Campus Zacatecas del Instituto Politécnico Nacional (IPN)</b>            Principales intereses de investigación en redes neuronales artificiales, métodos de optimización, robótica y machine learning embebido. Docencia en unidades de aprendizaje de <i>Microcontroladores y Procesador Digital de Señales</i>.</p> <p><b>15/06/2015 – 22/08/2018. Profesor de cátedra en el Instituto Tecnológico y de Estudios Superiores de Monterrey, Campus Zacatecas (ITESM).</b> Profesor de cátedra, investigador y mentor del grupo de robótica de la Prepa Tec.</p> <p><b>15/06/2011 al 20/02/2013. Profesor de asignatura en el Instituto Tecnológico Superior de Jerez (TNM)</b>            Coordinador de los proyectos de Investigación Educativa, Innovación y Desarrollo Tecnológico e impartición de las asignaturas de <i>Electrónica Digital, Microcontroladores e Inteligencia Artificial</i>.</p> <p><b>01/02/2011 al 31/01/2012. Profesor en el Centro Universitario del Norte de la Universidad de Guadalajara (UDG)</b>            Coordinador del club de robótica e Impartición de las asignaturas de <i>Materiales y Dispositivos Electrónicos, Microondas y Satélites, Sistemas Robóticos e Inteligencia Artificial Clásica</i>.</p> <p><b>01/02/2007 al 30/09/2009. Consultor de Tecnología Educativa para Texas Instruments de México S. de R. L. de C.V.</b>            Desarrollo y planificación de estrategias para la incorporación de las nuevas tecnologías en la enseñanza de las matemáticas y ciencias para los niveles de educación básica, media superior y superior.</p>
<b>Educación y formación</b> Fecha y titulación obtenida Centro de formación	<p><b>12/02/2018 al 18/03/2022. Doctorado en Ingeniería y Tecnología Aplicada.</b> Cédula Profesional: 12794071. Unidad Académica de Ingeniería Eléctrica de la Universidad Autónoma de Zacatecas. México.</p> <p><b>01/10/2009 al 30/09/2010. Maestría en Sistemas Electrónicos para Entornos Inteligentes.</b> Cédula Profesional: 11537361. Escuela Técnica Superior de Ingeniería de Telecomunicación de la Universidad de Málaga. España.</p> <p><b>01/08/2002 al 31/07/2007. Ingeniero en Comunicaciones y Electrónica.</b> Cédula Profesional: 5766661. Centro Universitario de Ciencias Exactas e Ingenierías de la Universidad de Guadalajara. México.</p> <p><b>04/08/1997 al 10/07/2000. Técnico en Computación.</b> Cédula Profesional: 4370379. Centro de Estudios Tecnológicos industrial y de servicios No. 114. Jerez, Zacatecas. México.</p>
<b>Habilidades y competencias personales</b> Otros idiomas Habilidades sociales Habilidades y competencias técnicas e informáticas	<p><b>Inglés. Certificado TOEFL ITP® Nivel B1.</b></p> <p><b>Facilidad para trabajar en equipo y en ambientes multiculturales.</b></p> <p><i>Redes neuronales artificiales, redes de sensores inalámbricos. Programación de microcontroladores de 16 y 32 bits en familias MSP430 de ultra bajo consumo de Texas Instruments y arquitecturas ARM Cortex™-M3 y Cortex™-M4. Programación de procesadores digitales de señales (DSPs) en familias C5000 de bajo consumo y C6000 singlecore.</i></p>
<b>Artículos de investigación científica</b>	<p>T. Ibarra-Pérez, R. Jaramillo-Martínez, H.C. Correa-Aguado, C. Ndjatchi, M.d.R. Martínez-Blanco, H.A. Guerrero-Osuna, F.D. Mirelez-Delgado, J.I. Casas-Flores, R. Reveles-Martínez, and U.A. Hernández-González, "A Performance Comparison of CNN Models for Bean Phenology Classification Using Transfer Learning Techniques," <i>AgriEngineering</i> vol. 6, no. 1, p. 841-857, Mar 2024, doi: 10.3390/agriengineering6010048.</p> <p>M. A. Torres-Hernández, M. H. Escobedo-Barajas, H. A. Guerrero-Osuna, T. Ibarra-Pérez, L. O. Solís-Sánchez, and M. del R. Martínez-Blanco, "Performance Analysis of Embedded Multilayer Perceptron Artificial Neural Networks on Smart Cyber-Physical Systems for IoT Environments," <i>Sensors</i>, vol. 23, no. 15, p. 6935, Aug. 2023, doi: 10.3390/s23156935.</p> <p>H. A. Guerrero-Osuna, J. A. Nava-Pintor, C. A. Olvera-Olvera, T. Ibarra-Pérez, R. Carrasco-Navarro and L. F. Luque-Vega, "Educational Mechatronics Training System Based on Computer Vision for Mobile Robots," <i>Sustainability</i>, vol. 15, no. 2, Jan. 2023, 1386, doi: 10.3390/su15021386.</p> <p>H. C. Correa-Aguado, J. C. Álvarez-Salazar, L. M. González-Rodríguez, and T. Ibarra-Pérez, "Photocatalytic Biodiesel Production with TiO<sub>2</sub>," <i>Biotechnología y Sustentabilidad</i>, vol. 8, no. 1, p. 42-51, Dec. 2023, doi: 10.57737/biotechnologiaysust.v8i1.2324</p> <p>G. V. Cerrillo-Rojas, T. Ibarra-Pérez, and H. C. Correa-Aguado, "Infrared irradiation: a novel method to assist photosynthetic pigment extraction in microalgae," <i>Biotechnología y Sustentabilidad</i>, vol. 7, no. 1, Jan. 2023, doi: 10.57737/biotechnologiaysust.v7i1.1646</p> <p>J. C. Álvarez-Salazar, G. V. Cerrillo-Rojas, T. Ibarra-Pérez, and H. C. Correa-Aguado, "Yodo Molecular: Un Eficiente Catalizador en la Síntesis de Biodiesel," <i>Academia Journals</i>, vol. 15, no. 3, p. 7.6-7.11, Apr. 2023.</p> <p>T. Ibarra-Pérez, J. M. Ortiz-Rodríguez, F. Olivera-Domingo, H. A. Guerrero-Osuna, H. Gamboa-Rosales, and M. del R. Martínez-Blanco, "A Novel Inverse Kinematic Solution of a Six-DOF Robot Using Neural Networks Based on the Taguchi Optimization Technique," <i>Applied Sciences</i>, vol. 12, no. 19, p. 9512, Jan. 2022, doi: 10.3390/app12199512.</p> <p>T. Ibarra-Pérez, M. Del Rosario Martínez-Blanco, F. Olivera-Domingo, J. M. Ortiz-Rodríguez, and J. Gomez-Escribano, "A novel optimization robust design of artificial neural networks to solve the inverse kinematics of a manipulator of 6 DOF," in <i>2021 22nd IEEE International Conference on Industrial Technology (ICIT)</i>, Mar. 2021, vol. 1, pp. 838–843. doi: 10.1109/ICIT46573.2021.9453701.</p> <p>Ma. del R. Martínez-Blanco, T. Ibarra-Pérez, F. Olivera-Domingo, and J. M. Ortiz-Rodríguez, "Optimization of Training Data Set Based on Linear Systematic Sampling to Solve the Inverse Kinematics of 6 DOF Robotic Arm with Artificial Neural Networks," in <i>Frontiers</i></p>

of Data and Knowledge Management for Convergence of ICT, Healthcare, and Telecommunication Services, S. Paul, S. Paiva, and B. Fu, Eds. Cham: *Springer International Publishing*, 2022, pp. 85–112. doi: 10.1007/978-3-030-77558-2\_5.

Ma. del R. Martínez, T. Ibarra-Pérez, F. Olivera-Domingo, and J. M. Ortiz-Rodríguez, “Robust Design of Artificial Neural Network Methodology to Solve the Inverse Kinematics of a Manipulator of 6 DOF,” in *Artificial Intelligence (AI): Recent Trends and Applications*, S. K. Suguna, M. Dhivya, and S. Paiva, Eds. *CRC Press*, 2021, pp. 171–210. doi: 10.1201/9781003005629.

T. Ibarra-Pérez, J. M. Ortiz-Rodríguez, M. del R. Martínez-Blanco, and F. Olivera-Domingo, “Rendimiento en redes neuronales de propagación inversa mediante la aplicación de algoritmos de reducción de datos en la solución de la cinemática inversa de un manipulador robótico de 6-GDL,” in *2019 International Symposium on Solid State Dosimetry*, Oct. 2019, vol. 3, pp. 127–147.

T. Ibarra, F. Olivera, y A. Prado, “Diseño de juegos inteligentes para el desarrollo de habilidades psicomotrices en niños con síndrome de Down”, presentado en el *II Seminario Permanente de Investigación Científica de la Universidad de Guadalajara*, Guadalajara, México, 2014.

T. Ibarra, F. Olivera, y A. Prado, “Objetos inteligentes en ejercicios de motricidad fina aplicados a pacientes con daño cerebral adquirido (DCA)”, presentado en el *Congreso Internacional de Software Libre*, Zacatecas, México, 2014.

T. Ibarra, y F. Olivera, “Internet de las cosas: una apuesta al futuro,” *eeek’ Revista de divulgación científica del COZCYT*, vol.3, no. 5, pp. 11-12, Nov. 2014. ISSN: 2007-4565.

T. Ibarra, “El poder de nuestras neuronas,” *eeek’ Revista de divulgación científica del COZCYT*, vol. 4, pp. 11-12, Jun 2012. ISSN: 2007-4565.

## Artículos de divulgación científica

## Premios y distinciones

**Distinción de Candidato a Investigador Nacional SNII-CONAHCYT** en el área VIII: Ingenierías y Desarrollo Tecnológico para el periodo comprendido del 1 de enero de 2023 al 31 de diciembre de 2026.

**Miembro del Sistema Estatal de Investigadores en Gobierno del Estado de Zacatecas** durante el periodo 2023-2027.

**Reconocimiento en el programa de Estímulos al Desempeño de los Investigadores Nivel 6** en el Instituto Politécnico Nacional para el periodo comprendido del 1 de abril de 2023 al 31 de marzo de 2025.

**Mención Honorífica** en la defensa de Tesis para obtener el grado de Doctor en Ingeniería y Tecnología Aplicada en la Unidad Académica de Ingeniería Eléctrica de la Universidad Autónoma de Zacatecas. Abril 2022.

**Primer lugar nacional en el "V Concurso Nacional la Ciencia para Todos"**, organizado por el Fondo de Cultura Económica (FCE), el Consejo Nacional de Humanidades, Ciencia y Tecnología (CONAHCYT), la Universidad Nacional Autónoma de México (UNAM), la Universidad Autónoma Metropolitana (UAM), la Academia Mexicana de Ciencias (AMC) y la Secretaría de Educación Pública (SEP). Septiembre de 1998.

**Primer lugar en etapa estatal en el "II Concurso Nacional de Especialidades"** dentro del marco del “V Festival Académico de la Dirección General de Educación Tecnológica Industrial” (DGETI). Mayo 1999.

**Segundo lugar en el concurso del reto Intel® Galileo en evento nacional Campus Party.** Zapopan, Jal. México. 2014.

## Conferencias, ponencias y talleres impartidos en congresos nacionales e internacionales

**Ponencia** “Metodología para el diseño de sistemas automatizados”. I Congreso de Calidad Educativa de la DGETI. Dirección General de Educación Tecnológica Industrial, 2000. **Zacatecas, Zac. México.**

**Conferencia** “Texas Instruments. Programación y Aplicaciones en la Ingeniería Civil”. 4ª Semana de la Ingeniería Civil. Centro Universitario de Ciencias Exactas e Ingenierías de la Universidad de Guadalajara, 2006. **Guadalajara, Jal. México.**

**Taller** “Introducción al Manejo de las Graficadoras Texas Instruments”. Centro Universitario de Ciencias Exactas e Ingenierías de la Universidad de Guadalajara, 2006. **Guadalajara, Jal. México.**

**Ponencia** “Control de platinas mediante LabVIEW”. III Jornada de motivación a la investigación. Universidad de Guadalajara, 2006. **Guadalajara, Jal. México.**

**Conferencia Magistral** “Uso de tecnologías aplicadas en el aula”. Aniversario de la Universidad del Valle de Atemajac Campus León UNIVA, 2007. **León, Gto. México.**

**Ponencia** “Calculadoras Graficadoras y sus Aplicaciones en la Ingeniería”. 1ra. Sesión de Talleres para Ingenierías. ITESM Tecnológico de Monterrey Campus Guadalajara, 2007. **Guadalajara, Jal. México.**

**Conferencia** “Manejo de Calculadoras de Texas Instruments”. Universidad Marista de San Luis Potosí, 2007. **San Luis Potosí, S. L. P. México.**

**Conferencia** “Texas Instruments, como una herramienta útil de trabajo”. 4º Congreso Internacional de Ingeniería Química y Alimentos. XXIII Reunión Nacional Estudiantil. Universidad de las Américas Puebla, 2007. **Puebla, Pue. México.**

**Ponencia** “Texas Instruments en la Ingeniería”. XV Congreso Nacional de Ingeniería Mecánica Eléctrica. Universidad Veracruzana zona Xalapa, 2007. **Xalapa-Enríquez, Ver. México.**

**Taller** “Uso de Calculadora Voyage™200”. Rama Estudiantil IEEE Morelia. Instituto Tecnológico de Morelia, 2007. **Morelia, Mich. México.**

**Ponente** “Tecnología Educativa en la Enseñanza de las Matemáticas y Ciencias”. II Seminario de Matemática Educativa Aplicada. Universidad Autónoma de Nayarit, 2007. **Tepic, Nay. México.**

**Conferencia** “Aplicaciones de Ingeniería Eléctrica y Electrónica con la Voyage™200 Módulos básico, MEPRO, EEPRO y Logix”. Rama Estudiantil IEEE Veracruz. Instituto Tecnológico de Veracruz, 2007. **Veracruz, Ver. México.**

**Conferencia** “Texas Instruments en la Ingeniería Electrónica”. Aniversario de la carrera de Ingeniería Electrónica. Universidad Iberoamericana, 2007. **México D.F.**

**Taller** “Texas Instruments en la Ingeniería Química”. XXIV Reunión Nacional Estudiantil. Instituto Mexicano de Ingenieros Químicos A.C. Universidad Autónoma de Nuevo León, 2008. **Monterrey, N. L. México.**

**Ponencia** “Modelos de Enseñanza Colaborativa en el Aprendizaje de las Matemáticas con TI-Navigator™”. XXI Congreso Nacional de Enseñanza de las Matemáticas. ANPM A.C., 2008. **Zacatecas, Zac. México.**

**Taller** “Manejo básico de Calculadoras Voyage™200”. Universidad Politécnica de Aguascalientes, 2008. **Aguascalientes, Ags. México.**

**Taller** “La Calculadora Voyage™200”. Universidad del Golfo de México Campus Orizaba, 2008. **Orizaba, Ver. México.**

**Ponencia** “Aplicación de Calculadoras en la Ingeniería”. XVI Congreso Nacional de Ingeniería Mecánica Eléctrica. Universidad Veracruzana zona Xalapa, 2008. **Xalapa-Enríquez, Ver. México.**

**Ponencia** “La enseñanza de la física con apoyo de tecnología”. XI Simposio Internacional de Física. ITESM Tecnológico de Monterrey Campus Monterrey, 2009. **Monterrey, N. L. México.**

**Ponencia** “Aprendizaje Cooperativo con TI-Navigator™”. XXIII Reunión Latinoamericana de Matemática Educativa. Universidad Autónoma de Santo Domingo, 2009. **Santo Domingo, República Dominicana.**

**Taller** “La enseñanza de las matemáticas asistida con tecnología”. Primer Congreso Estatal de Investigación Educativa en Matemáticas. Secretaría de Educación del Estado de Yucatán, 2009. **Mérida, Yuc. México.**

**Conferencia** “Uso de Calculadoras Voyage™200”. 2º Congreso Internacional de Industria y Tecnología. ITESM Tecnológico de Monterrey Campus Hidalgo, 2009. **Pachuca, Hgo. México.**

**Taller** “Manejo y programación de aplicaciones para ingeniería con la calculadora Voyage™200 de Texas Instruments”. Centro Universitario del Norte de la Universidad de Guadalajara, 2011. **Colotlán, Jal. México.**

**Conferencia** “Sistemas inteligentes basados en dispositivos móviles con Android y microcontroladores MSP430 de Texas Instruments”. Feria de la Tecnología. Centro Universitario del Norte de la Universidad de Guadalajara, 2012. **Colotlán, Jal. México.**

**Conferencia** “Programación de Dispositivos Móviles”. Expo UPIIZ. Unidad Profesional Interdisciplinaria de Ingeniería Campus Zacatecas del Instituto Politécnico Nacional, 2012. **Zacatecas, Zac. México.**

**Conferencia** “Sistemas Embebidos”. Feria de la Tecnología. Centro Universitario del Norte de la Universidad de Guadalajara, 2013. **Colotlán, Jal. México.**

**Ponencia** “Inteligencia Artificial Aplicada a la Robótica”. XX Semana Nacional de Ciencia y Tecnología. Centro de Bachillerato Tecnológico industrial y de servicios No. 23, 2013. **Zacatecas, Zac. México.**

**Ponencia** “Redes de Sensores Inalámbricos”. 1er. Jornada y Panel de Conocimientos. Unidad Profesional Interdisciplinaria de Ingeniería Campus Zacatecas del Instituto Politécnico Nacional, 2013. **Zacatecas, Zac. México.**

**Conferencia** “Sistemas Embebidos”. 4º Aniversario de la UPIIZ. Expo UPIIZ. Unidad Profesional Interdisciplinaria de Ingeniería Campus Zacatecas del Instituto Politécnico Nacional, 2013. **Zacatecas, Zac. México.**

**Ponencia** “Diseño de juegos inteligentes para el desarrollo de habilidades psicomotrices en niños con síndrome de Down”. II Seminario Permanente de Investigación. Centro Universitario del Norte de la Universidad de Guadalajara, 2014. **Colotlán, Jal. México.**

**Ponencia** “Objetos inteligentes en ejercicios de motricidad fina aplicados a pacientes con daño cerebral adquirido (DCA)”. 3er. Congreso Internacional de Software Libre, 2014. **Zacatecas, Zac. México.**

**Conferencia** “Internet de las cosas”. Feria de la Tecnología. Centro Universitario del Norte de la Universidad de Guadalajara, 2017. **Colotlán, Jal. México.**

**Conferencia** “Predicción de fallas en líneas de producción industrial con inteligencia artificial”. Ciclo de conferencias. Tecnológico Nacional de México Campus Jerez, 2018. **Jerez, Zac. México.**

**Ponencia** “Impresión 3D, ensamble e instrumentación de un manipulador robótico de seis grados de libertad llamado UpiizLIDTIA-IPN”. 20º Seminario de Investigación. Universidad Autónoma de Aguascalientes, 2019. **Aguascalientes, Ags. México.**

**Ponencia** “A novel optimization robust design of artificial neural networks to solve the inverse kinematics of a manipulator of 6 DOF”. 22nd IEEE International Conference on Industrial Technology. Universidad Politécnica de Valencia, 2021. **Valencia, España.**